

## **Guia 3 ITI : Resolucion**

Di Maria, Franco Martín,  
*Padrón : 100498*  
2do. Cuatrimestre de 2019  
75.06 - Organización de Datos  
Facultad de Ingeniería  
Universidad de Buenos Aires

## 1. Ejercicio 1

### 1.1. Enunciado

Se tiene un archivo con 10 caracteres en total formado por tres caracteres distintos (ej: ABC). De todos los archivos posibles con estas características mostrar el archivo de máxima entropía que se pueda comprimir mejor usando LZ77. No es necesario comprimir el archivo.

### 1.2. Solución

Sea X, un archivo con 10 caracteres en total formado por tres caracteres distintos (ej: ABC).

Se desea que entropía del archivo X ( $H(X)$ ) sea máxima, pero compresible.

$$H(X) = \sum_{i=0} P_i \log_2(P_i) = P_a \log_2(P_a) + P_b \log_2(P_b) + P_c \log_2(P_c)$$

$H(X)$  es máximo cuando:

$$P(a) = P(b) = P(c) = \frac{1}{3}$$

Pues entonces los 3 caracteres son equiprobables.

Pero la longitud del archivo es de 10 caracteres, por lo que uno de ellos deberá tener una probabilidad:

$$P(x_0) = \frac{4}{10}$$

$$x_0 \in \{a, b, c\}$$

mientras que para los otros dos será:

$$P(x_1) = P(x_2) = \frac{3}{10}$$

$$x_1 \in \{a, b, c\} - \{x_0\}$$

$$x_2 \in \{a, b, c\} - \{x_0, x_1\}$$

LZ77 (o LZSS, formalmente hablando), comprime a base de repeticiones de patrones, de un largo mínimo igual a 2 caracteres.

Un archivo de máxima entropía, pero fácilmente compresible por LZ77 podría ser:

A A A B B B C C C

#### 1.2.1. Compresión por LZ77 (no pedido por el enunciado)

0A 1(0,2) 0B 1(0,2) 0C 1(0,2)

### 1.3. EXTRA : ¿Y si fuese el menos compresible, pero aun así compresible por LZ77?

Un archivo incompresible por LZ77, puede ser el siguiente:

A A B A C C B B C A

En este caso todos los patrones son : AA, AB, BA, AC, CC, CB, BB, BC, CA, AAB, ABA, BAC, etc ...

Como se podrá comprobar ninguno de estos patrones se repite por lo que la complejidad será máxima, y no se podrá comprimir mediante el LZ77

Para hallar un archivo que se pueda comprimir, y mantener tal grado de complejidad, se puede reemplazar al ultimo carácter del archivo anterior, por otro que provoque la repetición de un patrón. Por ejemplo, podría reemplazar la ultima A por una C, de forma de obtener el siguiente archivo:

A A B A C C B B C C

En este caso, se repite el patrón CC, por lo ahora el archivo es comprimible por LZ77.

#### 1.3.1. Compresión por LZ77

La compresión LZ77 del ultimo archivo podría ser l siguiente:

0A 0A 0B 0A 0C 0C 0B 0B 1(3,2)

## 2. Ejercicio 2

### 2.1. Enunciado

Explique en que casos sería una buena idea usar un compresor aritmético estático de orden 3.

### 2.2. Solución

Del apunte de la cátedra [1], para cualquier algoritmo de compresión estadístico:

En un modelo de orden "n" la frecuencia de cada carácter se calcula en base a los "n" caracteres anteriores. Cada combinación de "n" caracteres del archivo nos proporciona un contexto y en base a dicho contexto calculamos la probabilidad del carácter siguiente.

Por lo tanto, un compresor aritméticos de orden 3, conviene usarlo, cuando en el archivo hay varios patrones de 3 caracteres, repetidos.

Además, al ser estático, estaríamos guardando tablas de frecuencias para cada contexto de 3 caracteres. Si solo consideramos los 256 caracteres posibles de la tabla ASCII, estas tablas estarán ocupando 4GB en el archivo comprimido.

Para que la compresión tenga sentido, y estas tablas no terminen aumentando el tamaño del archivo en lugar de reducirlo, necesitaríamos que el archivo sea bastante grande, es decir, que originalmente ocupe un tamaño mucho mayor a estos 4GB mencionados.

Esto vale para cualquier compresor estadístico estático de orden 3.

Específicamente para compresión aritmética, habría que agregar que destaca sobre otros algoritmos (como Huffman), si la longitud óptima de los códigos (de la codificación de los símbolos) es una cantidad no entera de bits.

### **3. Ejercicio 3**

#### **3.1. Enunciado**

Tenemos un compresor aritmético dinámico de orden 0 que trabaja procesando bit por bit. Si comprimimos un archivo que está formado por una serie de 1000 bits en 1 y luego dos bits en 0. ¿cuántos bits ocupará el archivo comprimido

### 3.2. Solución

*Intervalo inicial* =  $[0, 1)$

$$\text{bit } 0 \quad \parallel \quad P(1) = \frac{1}{2} \quad P(0) = \frac{1}{2} \quad \parallel \quad \text{Nuevo intervalo} = [0, 1 * \frac{1}{2}) = [0, \frac{1}{2})$$

$$\text{bit } 1 \quad \parallel \quad P(1) = \frac{2}{3} \quad P(0) = \frac{1}{3} \quad \parallel \quad \text{Nuevo intervalo} = [0, \frac{1}{2} * \frac{2}{3}) = [0, \frac{1}{3})$$

$$\text{bit } 2 \quad \parallel \quad P(1) = \frac{3}{4} \quad P(0) = \frac{1}{4} \quad \parallel \quad \text{Nuevo intervalo} = [0, \frac{1}{3} * \frac{3}{4}) = [0, \frac{1}{4})$$

$$\text{bit } n \quad \parallel \quad P(1) = \frac{n+1}{n+2} \quad P(0) = \frac{1}{n+2} \quad \parallel \quad \text{Nuevo intervalo} = [0, \frac{1}{n+2})$$

$(n \in [0, 999])$

$$\text{bit } 999 \quad \parallel \quad P(1) = \frac{1000}{1001} \quad P(0) = \frac{1}{1001} \quad \parallel \quad \text{Nuevo intervalo} = [0, \frac{1}{1002})$$

*Siguen los ultimos dos bits que son 0 :*

$$\begin{aligned} \text{bit } 1000 \quad \parallel \quad P(1) &= \frac{1000}{1002} \quad P(0) = \frac{2}{1002} \\ \parallel \quad \text{Nuevo intervalo} &= [\frac{1000}{(1002)^2}, \frac{1}{1002}) \end{aligned}$$

$$\begin{aligned} \text{bit } 1001 \quad \parallel \quad P(1) &= \frac{1000}{1003} \quad P(0) = \frac{3}{1003} \\ \parallel \quad \text{Nuevo intervalo} &= [\frac{(1000)^2}{1003 * (1002)^2}, \frac{1}{1002}) \end{aligned}$$

## 4. Ejercicio 4

Una planta industrial decidió instalar un sistema monitor de temperatura, afin de obtener registro de las variaciones que existen, y poder tomar acciones de ser necesario. Dicho monitor cuenta con un sensor que emite cada 5 segundos un registro (fecha: AAAAMMDD , hora: HH:MM:SS , Temperatura: XX.XX , Variación: Numérico, puede ser positivo o negativo). Más allá de las acciones inmediatas que se puedan tomar, esta información se quiere almacenar para realizar consultas o análisis a futuro. Se pide proponer una solución que permita almacenar estos datos comprimidos. Se pueden utilizar uno o más algoritmos de los vistos en clase, o proponer variantes adaptadas a la estructura específica de los datos con los que se cuentan. Se debe explicar cómo queda la estructura final del archivo, y el análisis en el que se basó la solución.

**4.1. Enunciado****4.2. Solución****5. Ejercicio 5****5.1. Enunciado**

Determinar si las siguientes afirmaciones son V / F justificando la respuesta:

**5.1.1. Item A**

La entropía es una aproximación de cuanto se puede comprimir, dado que no podemos calcular cuanto se puede comprimir un string

**5.1.2. Solución****5.1.3. Item B**

Una forma posible de comprimir un stream de datos es utilizar un huffman estático.

**5.1.4. Solución****5.1.5. Item C**

La entropía puede utilizarse para construir clasificadores de texto.

**5.1.6. Solución****5.1.7. Item D**

Un compresor estadístico estático comprime siempre mejor que un compresor estadístico dinámico.

**5.1.8. Solución****5.1.9. Item E**

Podemos determinar la longitud final del archivo comprimido utilizando huffman estático de orden 1, calculando la entropía y multiplicándola por la cantidad de caracteres del archivo.

**5.1.10. Solución****5.1.11. Item F**

Tenemos 2 archivos, uno con longitud pequeña y el otro muy grande que se comprimen utilizando huffman estático de orden 5. Si observamos que tienen la mismas tablas de frecuencias podemos afirmar que el cociente entre el tamaño del archivo sin comprimir y el tamaño del archivo comprimido será similar.

**5.1.12. Solución****5.1.13. Item G**

Todo archivo con complejidad de kolmogorov baja tendrá una entropía de Shannon baja.

**5.1.14. Solución****5.1.15. Item H**

Es imposible que un archivo comprimido mediante huffman estático de orden 1 iguale la máxima compresión dada por la entropía del mismo

**5.1.16. Solución****6. Bibliografía****Referencias**

- [1] 75.06, 95.58 Organización de Datos - Apunte del Curso - October 19, 2018 - v2.0 ; Luis Argerich, Natalia Golmar, Damián Martinelli, Martín Ramos Mejía, Juan Andrés Laura - Universidad de Buenos Aires - Facultad de Ingeniería